

Метод подстановки для получения оценок функционалов от функции распределения генеральной совокупности

Идея в замене в функционале функции F на функцию F_n , или в замене распределения P на выборочное распределение P_n

Оценивание моментов генеральной совокупности

$\xi \sim P, \alpha_k = E\xi^k$ - k -ый выборочный момент, $\mu_k = E(\xi - \alpha_1)^k$ - k -ый выборочный центральный момент

Выразим их с помощью P , сделаем замену, и получим оценки

$$\alpha_k = \int_{\mathbb{R}^1} x^k dP$$

$$A_k = \int_{\mathbb{R}^1} x^k dP_n = \frac{1}{n} \sum_{i=1}^n X_i^k, A_k - \text{оценка для } \alpha_k$$

$$\bar{X} = A_1 = \frac{1}{n} \sum_{i=1}^n X_i \text{ называется выборочным средним}$$

$$\mu_k = \int_{\mathbb{R}^1} (x - \alpha_1)^k dP = \int_{\mathbb{R}^1} (x - \int_{\mathbb{R}^1} x dP)^k dP$$

$$M_k = \int_{\mathbb{R}^1} (x - \int_{\mathbb{R}^1} x dP_n)^k dP_n$$

$$M_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k = \overline{(X - \bar{X})^k}$$

$$S_n^2 = M_2 = \overline{(X - \bar{X})^2} \text{ называется выборочной дисперсией}$$

$$S_n^2 = \overline{X^2} - \bar{X}^2$$

$$M_k = \sum_{i=0}^k C_k^i X_i \cdot (-1)^{k-i} (\bar{X})^{k-i} = \sum_{i=0}^k (-1)^{k-i} C_k^i X_i \cdot (\bar{X})^{k-i} = \sum_{i=0}^k (-1)^{k-i} C_k^i \bar{X}^i \cdot (\bar{X})^{k-i}$$

$$\text{Проверка для } k=2: (\bar{X})^2 - 2\bar{X} \cdot \bar{X} + \bar{X}^2 = \bar{X}^2 - (\bar{X})^2 = S_n^2$$

Свойства оценок:

1) Свойство несмещённости оценок моментов

$$EA_k = E\left(\frac{1}{n} \sum_{i=1}^n X_i^k\right) = \frac{1}{n} \sum_{i=1}^n EX_i^k = \frac{1}{n} \sum_{i=1}^n \alpha_k = \alpha_k$$

A_k - несмещённая оценка для α_k

$$EM_2 = E\overline{X^2} - E(\bar{X})^2 = \alpha_2 - E(\bar{X})^2$$

$$E(\bar{X})^2 = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right)\left(\frac{1}{n} \sum_{j=1}^n X_j\right) = \frac{1}{n^2} \sum_{i=1}^n \sum_{j=1}^n EX_i X_j = \frac{1}{n^2} \left(\sum_{i=j} EX_i^2 + \sum_{i \neq j} EX_i X_j \right) = \frac{1}{n^2} (nEX_i^2 +$$

$$n(n-1)EX_i X_j) = \frac{1}{n} \alpha_2 + \frac{n-1}{n} \alpha_1^2 = \frac{1}{n} (\alpha_2 - \alpha_1^2) + \alpha_1^2 = \frac{\sigma^2}{n} + \alpha_1^2$$

$$EM_2 = \alpha_2 - \alpha_1^2 - \frac{\sigma^2}{n} = \sigma^2 - \frac{\sigma^2}{n}$$

Смещение оценки M_2 для μ_2 есть $-\frac{\sigma^2}{n}$ - средняя ошибка

Также можно определить качество оценки средним разбросом, то есть дисперсией

$$DA_k = D\left(\frac{1}{n} \sum_{i=1}^n X_i^k\right) = \frac{1}{n^2} \sum_{i=1}^n DX_i^k = \frac{1}{n} DX_1^k = \frac{1}{n} (EX_1^{2k} - (EX_1^k)^2)$$

$$DA_k = \frac{1}{n} (\alpha_{2k} - \alpha_k^2)$$

DS_n^2 посчитать сложнее, задача на семинар

2) Свойство состоятельности оценок моментов

$$A_{k,n} := A_k$$

$$A_{k,n} = \frac{1}{n} \sum_{i=1}^n X_i^k \xrightarrow[n \rightarrow \infty]{\mathbb{P}} EX_1^k = \alpha_k$$

Выборочный момент A_k - состоятельная оценка для α_k

Для выборочных центральных моментов понадобится лемма

Пусть имеются независимые случайные величины $\eta_1(n), \dots, \eta_k(n)$, и $\forall i \eta_i(n) \xrightarrow[n \rightarrow \infty]{\mathbb{P}} c_i = \text{const}$ и пусть $f(x_1, \dots, x_k)$ - функция, непрерывная в окрестности точки (c_1, \dots, c_k) .

Тогда $f(\eta_1(n), \dots, \eta_k(n)) \xrightarrow[n \rightarrow \infty]{\mathbb{P}} f(c_1, \dots, c_k)$

Доказательство

$$C_{n,\epsilon} = \{\omega \mid |f(\eta_1(n), \dots, \eta_k(n)) - f(c_1, \dots, c_k)| > \epsilon\}$$

$$? \mathbb{P}(C_{n,\epsilon}) \rightarrow_{n \rightarrow \infty} 0$$

$$\eta_i(n) \xrightarrow{\mathbb{P}} c_i, \text{ то есть } \forall i \forall \delta_i > 0 \mathbb{P}(\{|\eta_i(n) - c_i| > \delta_i\}) \rightarrow_{n \rightarrow \infty} 0$$

По непрерывности $\forall \epsilon > 0 \exists \delta_i > 0$: при $|x_i - c_i| < \delta_i$ $|f(x_1, \dots, x_k) - f(c_1, \dots, c_k)| < \epsilon$

Событие $C_{n,\epsilon}$ наступает, если $|\eta_i(n) - c_i| > \delta_i$ для некоторого i

$$C_{n,\epsilon} \subset \bigcup_{i=1}^k \{|\eta_i(n) - c_i| > \delta_i\}$$

$$\mathbb{P}(C_{n,\epsilon}) \leq \sum_{i=1}^k \mathbb{P}(\{|\eta_i(n) - c_i| > \delta_i\}) \rightarrow_{n \rightarrow \infty} 0 - \text{QED}$$

$$S_n^2 = A_{2,n} - (A_{1,n})^2 = f(A_{1,n}, A_{2,n}), \text{ где } f(x_1, x_2) = x_2 - x_1^2, f \text{ непрерывна в точке } (\alpha_1, \alpha_2)$$

$$\text{По лемме } S_n^2 \xrightarrow{\mathbb{P}}_{n \rightarrow \infty} \alpha_2 - \alpha_1^2 = \sigma^2$$

Выборочная дисперсия является состоятельной оценкой дисперсии генеральной совокупности

$$\gamma = \frac{\mu_3}{\sigma^3} = \frac{\mu_3}{(\alpha_2 - \alpha_1^2)^{3/2}} - \text{коэффициент асимметрии (отвечает за перекося распределения)}$$

$$\kappa = \frac{\mu_4}{\sigma^4} - 3 - \text{коэффициент эксцесса (отвечает за ширину распределения)}$$

$$\Gamma = \frac{M_3}{S_n^3}, K = \frac{M_4}{S_n^4} - 3 = \frac{(\overline{X - \bar{X}})^4}{(\overline{X - \bar{X}})^2} - 3 - \text{оценки для коэффициентов}$$

$$\tilde{S}_n^2 = \frac{n}{n-1} S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 - \text{исправленная выборочная дисперсия, несмещённая}$$

оценка для дисперсии

3) Асимптотическая нормальность оценок моментов

$$A_{k,n} - \text{оценка } \alpha_k, DA_{k,n} = \frac{\alpha_{2k} - \alpha_k^2}{n}$$

$$A_{k,n} - \alpha_k = \frac{1}{n} \sum_{i=1}^n (X_i^k - \alpha_k)$$

$$\frac{\sqrt{n}(A_{k,n} - \alpha_k)}{\sqrt{\alpha_{2k} - \alpha_k^2}} = \frac{\sum (X_i^k - \alpha_k)}{\sqrt{n} \sqrt{DX_1^k}} \xrightarrow{d}_{n \rightarrow \infty} \xi \sim N(0, 1) - \text{по центральной предельной теореме}$$

$$A_{k,n} \sim P = N(\alpha_k, \frac{\alpha_{2k} - \alpha_k^2}{n})$$

Точечное оценивание параметров распределения

$F(x, \theta)$ - статистическая модель, θ - параметр

Примеры:

1) Равномерная модель $R(\theta)$, $\theta \in \Theta = (0; +\infty)$

$$\text{Имеет плотность распределения } f(x, \theta) = \begin{cases} \frac{1}{\theta}, & x \in [0, \theta] \\ 0, & x \notin [0, \theta] \end{cases}$$

2) Нормальная модель $N(\theta_1, \theta_2^2)$, $(\theta_1, \theta_2) \in \Theta = \mathbb{R}^1 \times (0; +\infty)$

$$f(x, \theta_1, \theta_2^2) = \frac{1}{\sqrt{2\pi}\theta_2} \exp(-\frac{1}{2} \frac{(x - \theta_1)^2}{\theta_2^2})$$

3) $N(a, \theta^2)$ - нормальная модель с известным средним

4) $N(\theta, \sigma^2)$ - нормальная модель с известной дисперсией

5) Пуассоновская модель $P(\theta)$, $\theta > 0$

$$f(x, \theta) = \frac{\theta^x}{x!} e^{-\theta}, x = 0, 1, \dots, \text{ мера дискретная}$$

6) $Bi(k, \theta)$ - биномиальная модель, $\theta \in (0; 1)$

$f(x, \theta) = C_k^x \theta^x (1 - \theta)^{k-x}$, $x = 0, 1, \dots, k$ (среди k испытаний ровно x успехов, θ - вероятность успеха)

$$6') Bi(1, \theta), f(1, \theta) = \theta^x (1 - \theta)^{1-x}, x = 0, 1$$

7) $Bi(r, \theta)$ - отрицательная биномиальная модель, $\theta \in (0; 1)$

$f(x, \theta) = C_{x+r-1}^x \theta^x (1 - \theta)^r$ (до наступления r успехов было ровно x неудач, θ - вероятность неудачи)

8) $Bi(1, \theta)$ - геометрическое распределение

9) Гамма-распределение, $\lambda > 0$

$$f(x, \theta) = \frac{x^{\lambda-1} e^{-\frac{x}{\theta}}}{\Gamma(\lambda) \cdot \theta^\lambda}, \theta > 0$$

Случайные величины, зависящие только от выборки, а не от параметра, будем называть статистиками

Пусть $\tau(\theta)$ - функция от параметра

T - статистику, оценивающую $\tau(\theta)$ будем называть оценкой для $\tau(\theta)$ (оценка не должна содержать параметр)

T^* - оптимальная оценка, если

$$1) \forall \theta E_{\theta} T^* = \tau(\theta)$$

$$2) \text{ для любой другой несмещённой оценки } T \quad D_{\theta} T^* \leq D_{\theta} T$$

(Значения E и D зависят от параметра, даже если оценки от него не зависят)

Оценка называется эффективной, если её дисперсия совпадает с нижней границей дисперсий всех несмещённых оценок

Свойства оптимальных оценок

Теорема 1

Оптимальная оценка, если она существует, является единственной

Доказательство

Пусть T_1 и T_2 - оптимальные оценки

$$E_{\theta} T_1 = E_{\theta} T_2 = \tau(\theta), \quad D_{\theta} T_1 = D_{\theta} T_2 = v(\theta)$$

$$T = \frac{T_1 + T_2}{2}, \quad E_{\theta} T = \tau(\theta), \quad D_{\theta} T \geq v(\theta)$$

$T = T_1 = T_2$ - надо доказать

$$D_{\theta} T = \frac{1}{4}(D_{\theta} T_1 + D_{\theta} T_2 + 2\text{cov}(T_1, T_2)) \geq v(\theta)$$

$$2v(\theta) + 2\text{cov}(T_1, T_2) \geq 4v(\theta)$$

$$\text{cov}(T_1, T_2) \geq v(\theta)$$

$$|\text{cov}(T_1, T_2)| \leq \sqrt{D_{\theta_1} D_{\theta_2}} = v(\theta)$$

Имеет место равенство в неравенстве Коши-Буняковского-Шварца: $\text{cov}(T_1, T_2) = v(\theta)$

Случайные величины $T_1 - \tau(\theta)$ и $T_2 - \tau(\theta)$ линейно зависимы, $\exists c \neq 0, T_1 - \tau(\theta) = c(T_2 - \tau(\theta))$

$$D_{\theta} T_1 = c^2 D_{\theta} T_2 \Rightarrow c^2 = 1$$

$$v(\theta) = \text{cov}(T_1, T_2) = E(T_1 - \tau(\theta))(T_2 - \tau(\theta)) = cv(\theta) \Rightarrow c = 1 - \text{QED}$$

Теорема 2

Пусть T_1^* - оптимальная оценка для $\tau_1(\theta)$ и T_2^* - оптимальная оценка для $\tau_2(\theta)$

Тогда $\forall c_1, c_2 \quad \tilde{T} = c_1 T_1^* + c_2 T_2^*$ - оптимальная оценка для $\tau = c_1 \tau_1(\theta) + c_2 \tau_2(\theta)$

Доказательство

\tilde{T} - статистика, несмещённая для τ

Пусть T - несмещённая оценка для $\tau(\theta)$

$$D_{\theta} \tilde{T} = D_{\theta}(T - \tilde{T} + \tilde{T}) = D_{\theta}(T - \tilde{T}) + D_{\theta} \tilde{T} + 2\text{cov}(T - \tilde{T}, \tilde{T}) \geq D_{\theta} \tilde{T} + 2\text{cov}(T - \tilde{T}, \tilde{T})$$

Надо доказать, что $\text{cov}(T - \tilde{T}, \tilde{T}) = 0$

Заметим, что $E_{\theta}(T - \tilde{T}) = 0$

$$\hat{T}_1 = T_1^* + \lambda(T - \tilde{T}) - \text{несмещённая оценка } \tau_1(\theta)$$

$$D_{\theta} \hat{T}_1 \geq D_{\theta} T_1^* \quad \forall \lambda \in \mathbb{R}^1$$

$$D_{\theta} \hat{T}_1 = D_{\theta} T_1^* + \lambda^2 D_{\theta}(T - \tilde{T}) + 2\lambda \text{cov}(T_1^*, T - \tilde{T}) \geq D_{\theta} T_1^*$$

$\lambda^2 D_{\theta}(T - \tilde{T}) + 2\lambda \text{cov}(T_1^*, T - \tilde{T}) \geq 0$ - имеет 2 корня и всегда неотрицателен \Rightarrow корни совпадают $\Rightarrow \text{cov}(T_1^*, T - \tilde{T}) = 0$

$$\text{cov}(\tilde{T}, T - \tilde{T}) = c_1 \text{cov}(T_1^*, T - \tilde{T}) + c_2 \text{cov}(T_2^*, T - \tilde{T}) = 0 - \text{QED}$$